

Estructuras de Datos – CIN311/INF313/ICI313 (1/2026)

Proyecto Semestral - Entrega I

Consideraciones:

- Grupos de máximo 3 integrantes.
- Si alguno de los integrantes asiste a clases en sección miércoles, el grupo completo deberá presentar el día miércoles correspondiente a la fecha de entrega.
- Fecha de Entrega: 12-13 de Mayo, según corresponda a los integrantes del grupo.




Figura 1 – Representación gráfica de la construcción de un índice invertido a partir de diversos posts y los términos (palabras) utilizadas en su descripción.

Contexto del Proyecto

En el escenario actual de las redes sociales, la recuperación eficiente de información es un desafío crítico debido al volumen masivo de datos generados por segundo por los usuarios. Para que un usuario pueda localizar publicaciones específicas entre millones de registros, es inviable realizar escaneos secuenciales exhaustivos. Por ello, se utilizan estructuras de datos especializadas denominadas **Índices Invertidos**, las cuales constituyen la arquitectura central en plataformas como de recuperación de información, como los motores de búsqueda modernos.

Un índice invertido (ver Figura 1) permite invertir la relación jerárquica tradicional (donde un usuario posee posts) para crear una relación basada en términos. En esta estructura, cada palabra clave del post actúa como una entrada en un vocabulario que apunta a una lista de posteo. Dicha lista, implementada mediante estructuras dinámicas lineales (usualmente una lista enlazada), almacena las referencias a todos los objetos de tipo Post donde el término (en nuestro caso podemos considerar los hashtag) ha sido utilizado, permitiendo que las consultas se resuelvan en un tiempo proporcional al número de documentos relevantes y no al tamaño total de la base de datos.

Este proyecto requiere que el estudiante aplique conceptos fundamentales de Tipos de Datos Abstractos (TDA) y gestión de memoria dinámica para modelar no solo el contenido textual, sino también la estructura social de la red. Cabe destacar que los contactos de cada perfil no se gestionarán de forma lineal simple, sino que también mediante un Índice Invertido de Usuarios, permitiendo que el sistema identifique de manera eficiente a quiénes consideran "amigo" cada usuario específico.

Objetivo

Implementar la infraestructura base de un sistema de gestión de red social para modelar y visualizar la relación entre usuarios y sus publicaciones (posts). Los estudiantes deberán construir un Índice Invertido (ver Figura 1) utilizando estructuras de datos lineales para permitir búsquedas eficientes sobre el contenido generado por los usuarios y sobre los contactos de cada usuario.

Descripción del problema (Fase I: Construcción e Indexación)

El sistema debe procesar un conjunto de datos (*dataset*) de una red social real para representar de manera eficiente la relación entre términos (palabras), publicaciones y usuarios.

Modelamiento de Datos Requerido:

1. Usuarios: Cada perfil debe registrar sus datos básicos y una lista de sus conexiones o amigos.
2. Posts: Cada publicación debe estar vinculada a su autor y contener el texto original, además de una estructura que registre los "likes" y la identidad de los usuarios que los otorgaron.
3. **Índice Invertido:** Se debe utilizar este tipo de estructura (Figura 1) para gestionar a:
 - a. **Usuarios y sus contactos:** Para su implementación *puede utilizar el equivalente a un mapa o diccionario*, donde la clave corresponderá a cada usuario y, asociado a él, habrá una lista enlazada con sus contactos (implementada por Ud).
 - b. **Posts y los términos de su descripción:** Para su implementación *puede utilizar el equivalente a un mapa o diccionario*, donde la clave corresponderá a un término (o palabra) y, asociado a él, habrá una lista enlazada con los posts donde el término aparece en la descripción (implementada por Ud).

Requisitos Funcionales Mínimos

- a. Carga de Dataset: Procesar archivos de texto, CSV o JSON (entre otros) obtenidos desde fuentes como Kaggle (u otra fuente autorizada por el profesor) para poblar las estructuras de usuarios y publicaciones.
- b. Filtrado de Contenido: Eliminar "stopwords"¹ (palabras que no aporten a la búsqueda de los posts, como: preposiciones, artículos, etc.) tanto al construir el índice como al procesar las consultas del usuario.
- c. Representación en Memoria: Todo el manejo del índice y las relaciones sociales debe realizarse íntegramente en memoria dinámica utilizando listas enlazadas implementadas por los estudiantes.
- d. Funciones Base:
 - i. Creación del índice (puede requerir un pre-procesamiento de los datos).
 - ii. Inserción de publicaciones sin duplicidad.
 - iii. Búsqueda de:
 1. Usuarios: Amigos de un determinado usuario.
 2. Posts: Aquellos que contengan en su descripción ciertos términos individuales (puede ser basada en más de un término).

¹ Ver definición Stop Word en: <https://www.sciencedirect.com/topics/computer-science/stop-word-list>

Restricciones Técnicas

- 1) Lenguaje: Debe utilizarse estrictamente lenguaje C/C++, Python o Java.
- 2) Estructuras:
 - a) Índices Invertidos para gestionar usuarios y posts pueden implementarse sobre mapas o diccionarios, sujeto a:
 - i) Clave corresponde a:
 - (1) Nombres de usuario.
 - (2) Vocabulario generado a partir de los diferentes términos de cada post.
 - ii) Valor corresponde a la lista enlazada (implementada por los estudiantes) conteniendo:
 - (1) Contactos del usuario correspondiente, para el caso del índice invertido de usuarios y sus contactos.
 - (2) Posts que incluyen el hashtag correspondiente, para el caso de posts.
 - b) No se permite el uso de estructuras de datos avanzadas no vistas en clase durante la Unidad I (árboles, hash maps, etc.) para las listas de posteo ni la red de amigos.

Integridad Académica

1. Queda estrictamente prohibido el uso de LLMs (como ChatGPT, DeepSeek u otros) para:
 - a. Generación de código para cualquier parte de la entrega.
 - b. Procesamiento de los datos.
2. Su uso será sancionado con nota mínima y acciones según reglamento vigente de la Universidad.

Dataset

1. El dataset puede ser pre-procesado utilizando otros lenguajes o herramientas (AWK, etc).
2. El dataset elegido no puede ser utilizado por más de un grupo, para ello, deberán registrar el dataset seleccionado en la planilla compartida en: https://uvcl0-my.sharepoint.com/:w:/g/personal/alonso_inostrosa_uv_cl/IQD6tYi75hr-TpRVPZmR3D-5Aay4COyM_0w0gNjYvKWPq20

Entregables

1. Código Fuente: Implementación modularizada y clara de la solución, debe incluir archivo README.md con toda la documentación técnica que incluya instrucciones de compilación, descripción de las estructuras de datos y nombres descriptivos de las funciones.
2. Presentación (PPT): Una presentación para una defensa de 10 minutos.

Estructura sugerida para la Presentación

Considerando que la duración de la presentación no puede exceder los 10 Minutos, se recomienda la siguiente estructura:

1. Contexto (1 min): Presentación de integrantes y dataset seleccionado.
2. Estructuras (2 min): Diagrama de las listas enlazadas y vinculación entre Usuarios, Posts e Índice.
3. Procesamiento (2 min): Explicación del algoritmo de carga y filtrado de *stop words*.
4. Demostración en Video (4 min): Grabación de pantalla que muestre:
 - a. Partes importantes y relevantes del código fuente.
 - b. Funcionamiento del programa (carga y búsqueda de términos).

Consideraciones:

1. El video no debe contener audio, los integrantes deberán relatarlo en vivo.
 2. Reproducción del video no debe ser alterada (ni pausas, adelantar o retroceder).
5. Cierre (1 min): Gestión de memoria dinámica y conclusiones.

Elementos a Evaluar

Criterio a Evaluar	Puntaje Máximo
Correctitud y Funcionamiento: Carga de datos, filtrado de stop words y construcción correcta del índice invertido.	45
Estructuras de Datos: Definición e implementación propia de listas enlazadas y sublistas en memoria dinámica.	20
Calidad del Código: Modularización, comentarios, nombres descriptivos y gestión de memoria dinámica.	15
Documentación y Defensa: Calidad del archivo readme.md, claridad en la implementación y presentación de 10 minutos.	20
Total:	100